

TUGAS MACHINE LEARNING

Klasifikasi Tingkat Risiko COVID-19 di Indonesia

Pendekatan Klasifikasi Menggunakan Algoritma Random Forest

Ahmad Riko

Teknik Informatika

Latar Belakang

Pandemi COVID-19 di Indonesia menyebar dengan cepat dan tidak merata antar wilayah — beberapa provinsi mengalami tekanan kasus jauh lebih tinggi daripada yang lain.

Pengambil kebijakan membutuhkan cara cepat untuk mengetahui tingkat risiko suatu wilayah, agar respons (PPKM, alokasi tenaga medis, dsb.) dapat lebih tepat sasaran.

34

Provinsi di Indonesia terdampak

3

Tahun rentang data
(2020 – 2022)

3

Tingkat risiko yang
diklasifikasikan

Rumusan Masalah & Tujuan Penelitian

RUMUSAN MASALAH

- Bagaimana mengklasifikasikan tingkat risiko COVID-19 suatu provinsi secara otomatis?
- Fitur apa yang paling berpengaruh terhadap tingkat risiko suatu wilayah?
- Seberapa akurat algoritma Random Forest dalam melakukan klasifikasi ini?

TUJUAN PENELITIAN

- Membangun model klasifikasi tingkat risiko (Rendah/Sedang/Tinggi) menggunakan Random Forest
- Mengukur performa model melalui akurasi, precision, recall, dan F1-score
- Menganalisis feature importance untuk mengetahui faktor paling berpengaruh

Mengenal Algoritma Random Forest

Random Forest adalah algoritma ensemble learning yang membangun banyak decision tree secara acak, lalu menggabungkan hasilnya melalui voting mayoritas (untuk klasifikasi).



200 decision tree dilatih pada subset data & fitur yang berbeda (bagging), sehingga model lebih stabil dan tahan terhadap overfitting dibanding satu decision tree tunggal.

Dataset yang Digunakan

31.822

Total baris data

36

Kolom / atribut

34

Provinsi

2020–2022

Rentang waktu

Contoh kolom dalam dataset:

Date, Location, Province	Identitas waktu & wilayah
New Cases, Total Cases	Jumlah kasus harian & kumulatif
Total Active Cases	Kasus aktif per hari
Population, Population Density	Data demografi wilayah
Case Fatality / Recovered Rate	Indikator epidemiologi (%)

Sumber Data

COVID-19 Indonesia Dataset (Hendratno), diagregasi dari sumber resmi pemerintah, dipublikasikan di Kaggle.

Alur / Metodologi Penelitian



Pendekatan mengikuti alur standar supervised learning: mulai dari pembersihan data mentah hingga interpretasi hasil model.

Tahap Data Cleaning

1

Filter Level Wilayah

Hanya menggunakan baris level Provinsi; baris agregat nasional (Country) dibuang agar tidak terjadi duplikasi skala data.

2

Konversi Kolom Rate

Case Fatality Rate & Case Recovered Rate awalnya berupa teks ("51.28%") — dikonversi menjadi nilai numerik desimal.

3

Penanganan Missing Value

Nilai kosong pada fitur numerik diisi menggunakan median (imputasi), agar tidak mengurangi jumlah data secara signifikan.

4

Penanganan Nilai Tak Terhingga

Baris dengan pembagian tak valid (misal populasi 0) dibuang dari perhitungan target.


Membangun Target Klasifikasi: Risk Level

$$\text{Active_per_Million} = (\text{Total Active Cases} \div \text{Population}) \times 1.000.000$$

Wilayah dikelompokkan ke 3 kelas berdasarkan kuantil 33% dan 66% dari rasio kasus aktif per juta penduduk, agar jumlah data tiap kelas relatif seimbang.

- Rendah — $\leq$ kuantil 33%
- Sedang — 33% - 66%
- Tinggi — $>$ kuantil 66%

Distribusi Kelas Risk Level




Fitur yang Digunakan untuk Training

Demografi	Indikator Epidemiologi	Kontekstual
● Population Density ● Area (km2) ● Population ● Total Regencies ● Total Cities ● Total Districts	● Growth Factor of New Cases ● Growth Factor of New Deaths ● Case Fatality Rate ● Case Recovered Rate	● Island ● Month

12 fitur digunakan sebagai input model — kolom yang berpotensi bocor langsung ke target (misalnya Total Active Cases) tidak disertakan sebagai fitur.

Pembagian Data: Training & Testing



Ukuran Data Latih

24.714 baris (80%)

Ukuran Data Uji

6.179 baris (20%)

Metode Split

`train_test_split` dengan `stratify=y`

Alasan Stratifikasi

Menjaga proporsi kelas Rendah/Sedang/Tinggi tetap seimbang di data latih maupun data uji

Training Model Random Forest

RandomForestClassifier

Parameter	Nilai	Keterangan
n_estimators	200	Jumlah decision tree dalam forest
max_depth	None	Tree tumbuh hingga daun murni (tanpa batas kedalaman)
random_state	42	Seed acak agar hasil dapat direproduksi
n_jobs	-1	Memakai seluruh core CPU untuk mempercepat training

Model dilatih menggunakan teknik bagging (bootstrap aggregating): setiap tree dilatih pada subset data dan subset fitur acak, lalu hasil akhirnya digabung melalui voting mayoritas.

Hasil Evaluasi Model

95,19%


AKURASI MODEL

*pada 6.179 data uji
(20% dari total data)*

Kelas	Precision	Recall	F1-Score	Support
Rendah	0.98	0.97	0.97	2.039
Sedang	0.93	0.93	0.93	2.039
Tinggi	0.95	0.96	0.95	2.101


Model konsisten akurat di semua kelas — performa sedikit lebih rendah pada kelas "Sedang" karena secara alami tumpang tindih dengan kelas tetangganya (Rendah & Tinggi).

Confusion Matrix



Confusion matrix menunjukkan sebagian besar prediksi jatuh pada diagonal utama — artinya model jarang salah mengklasifikasikan kelas risiko yang berjauhan (misalnya Rendah diprediksi Tinggi).

Feature Importance



Insight

Case Recovered Rate & Case Fatality Rate mendominasi (>57% total importance) — indikator klinis lebih menentukan risiko daripada faktor demografis wilayah.

Kesimpulan & Saran

KESIMPULAN

- Random Forest mampu mengklasifikasikan tingkat risiko COVID-19 dengan akurasi 95,19%
- Case Recovered Rate & Case Fatality Rate adalah fitur paling berpengaruh
- Model stabil di seluruh kelas, dengan performa sedikit lebih rendah pada kelas "Sedang"

SARAN PENGEMBANGAN

- Hyperparameter tuning (GridSearchCV) untuk `n_estimators`, `max_depth`, `min_samples_leaf`
- Membandingkan performa dengan algoritma lain (KNN, SVM, Decision Tree)
- Menambahkan fitur time-series (lag & rata-rata bergerak) untuk menangkap tren temporal